TOGG Analiz Akışı Performans Raporu

Ses emosyonu ve WURSS — /togg-analyze uç noktası

Test tarihi	10 Kasım 2026, 15:34–16:01 UTC (18:34–19:01 TSİ)
Test edilen akış	POST /togg-analyze — 2 model, paralel çalışma
Ölçüm ortamı	AWS g4dn.xlarge: 4 vCPU, 16 GB RAM, NVIDIA T4 (16 GB); doğrudan sunucu bağlantısı
Kod sürümü	feat/prod-hardening, commit 3c255ad
Araç	Grafana k6 2.3.0; sunucuda 1 sn aralıklı CPU/GPU/RAM/güç kaydı
Belge durumu	Sürüm 1.0 — Şirket içi

1. Yönetici özeti

254 ms
Tek kullanıcı medyan yanıt süresi (ağ dahil)

268 ms
p95 — 702 istekte

~760 MB
İki modelin toplam boyutu

6,2 /sn
Tek sunucuda en yüksek analiz hızı

- **Tek kullanıcı senaryosunda** (araç içi kullanım) analiz sonucu uçtan uca **254 ms**'de dönmektedir; 3 dakika boyunca art arda gönderilen 702 isteğin tamamı eksiksiz sonuçlanmış, en kötü yanıt 483 ms olmuştur. Ölçüm ağ gidiş-dönüşü ve ses dosyası yüklemesini içerir; sunucu tarafı işlem süresi bunun altındadır.
- **Akış hafiftir:** iki base boyutlu ses modeli (WavLM ve Wav2Vec2, toplam ~760 MB) kullanılır, konuşma tanıma (STT) yoktur. Tüm modelleri çalıştıran genel analize göre **13 kat daha hızlıdır**.
- **Analiz başına donanım maliyeti düşüktür:** yaklaşık **0,08 GPU-saniye** ve **0,4 CPU çekirdek-saniye**.
- **Tek sunucu 100 eşzamanlı kullanıcıya kadar hatasız** çalışmıştır (toplam 4.419 istek, sıfır hata). En yüksek hız saniyede ~6,2 analizdir (saatte ~22.300).
- **Donanım tam yükte bile doymamaktadır** (CPU ~%60, GPU ~%39). Kapasite sınırı donanımdan değil, servislerin istekleri sırayla işlemesinden kaynaklanmaktadır; aynı donanımda artırılabilir.
- **Sınır:** 1.000 ve üzeri *aynı anda* gelen istekte sistem hata vermeye başlamakta, bir kısım yanıt modellerden biri eksik olarak dönmektedir. Bu durum bulut senaryosuna aittir; araç içi tek kullanıcı kullanımını etkilemez.

2. Amaç ve kapsam

Bu çalışmanın amacı, TOGG araç senaryosunda kullanılan analiz akışının performansını ölçmek ve modellerin kısıtlı donanıma (gömülü/araç içi sistemler) taşınabilirliğine dair veri üretmektir. Araç içi kullanımda tek bir kullanıcı vardır; bu nedenle birincil metrik **tek kullanıcı yanıt süresi**, ikincil metrik ise aynı akışın bulut üzerinden birden fazla araca hizmet verdiği senaryoda **sunucu kapasitesidir**.

2.1 Akıştaki modeller

Görev	Model	Mimari	Boyut
Ses emosyonu	voice_to_sentiment (wavlm_v6_multicrop_ema)	WavLM Base Plus + dikkat havuzlama, 4 sınıf	381 MB
WURSS (sağlık sinyali)	disease_service (usye)	Wav2Vec2 Base, ses sınıflandırma (sağlıklı / hasta)	378 MB

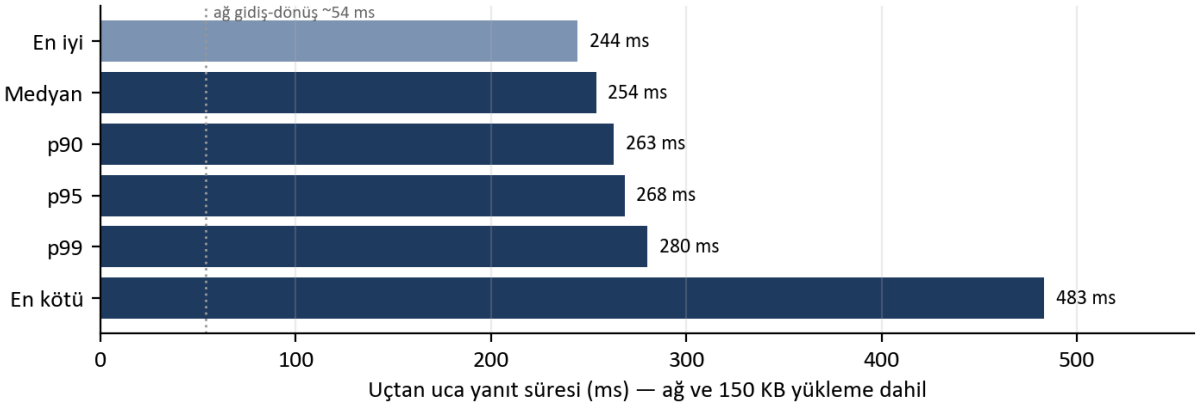
İki model aynı ses kaydı üzerinde **paralel** çalışır; yanıt her iki modelin sonucunu içerir. Boyutlar disk üzerindeki ağırlık dosyalarıdır (FP32). Akışta konuşma tanıma (Whisper vb.) bulunmamaktadır.

2.2 Yöntem

- Her istekte aynı 150 KB'lık Türkçe ses kaydı (m4a) gönderilmiştir.
- **Tek kullanıcı:** 1 sanal kullanıcı, 3 dakika boyunca bir önceki yanıtı aldıktan hemen sonra yeni istek gönderir.
- **Eşzamanlı kullanıcı:** N kullanıcı 3 dakika boyunca aynı şekilde istek gönderir. **Ani yük:** N istek aynı anda başlatılır.
- Her yanıtın içeriği kontrol edilmiştir: HTTP 200 dönüp modellerden birinin sonucu boş olan yanıtlar **kısmi** olarak ayrıca sayılmıştır.
- İstekler CDN (Cloudflare) atlanarak doğrudan sunucuya gönderilmiştir. İstemci–sunucu ağ gidiş-dönüşü ~54 ms'dir.
- Hata oranı 30 saniye sonra %50'yi aşan kademe otomatik durdurulmuştur.

3. Sonuçlar

3.1 Tek kullanıcı yanıt süresi (araç senaryosu)



Şekil 1 — Tek kullanıcı, 702 ardışık istek: yanıt süresi dağılımı

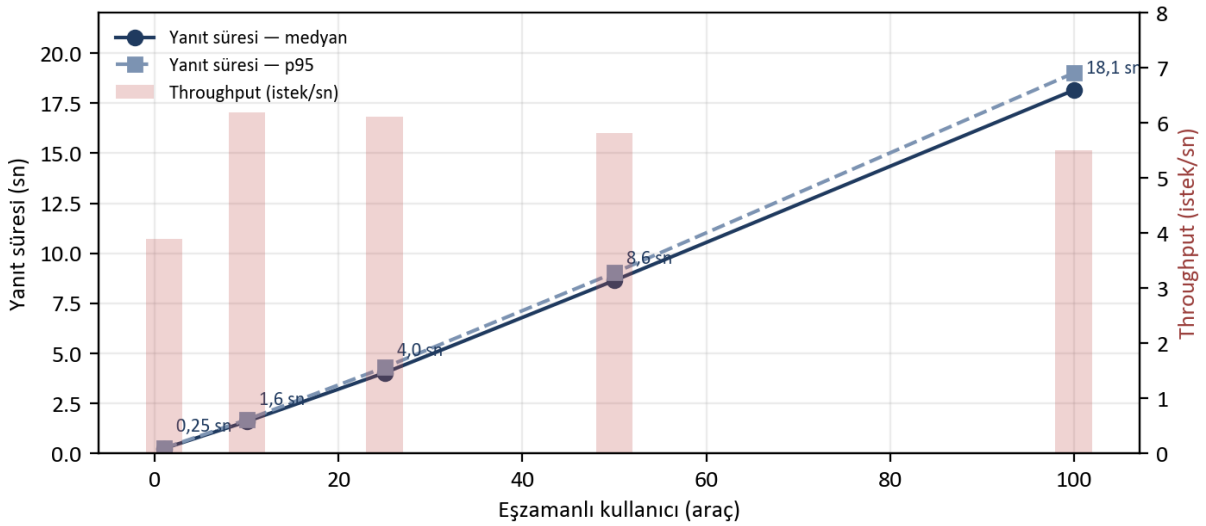
Yanıt süreleri dar bir aralıkta toplanmaktadır: isteklerin %90'ı 263 ms, %99'u 280 ms içinde tamamlanmıştır. Tek istekte ölçülen 497 ms, yeni bağlantı kurulumunu (TCP + TLS) içerdiği için ardışık isteklerden yüksektir. Hiçbir istekte hata veya eksik sonuç oluşmamıştır.

3.2 Eşzamanlı kullanıcı ve sunucu kapasitesi (bulut senaryosu)

Kademe	İstek	Tam sonuç	Kısmi	5xx	Bağlantı hatası	Medyan	p95	İstek/sn
1 istek	1	1 (%100)	0	0	0	0,50 sn	0,50 sn	1,47
Tek kullanıcı, art arda (3 dk)	702	702 (%100)	0	0	0	0,25 sn	0,27 sn	3,90
10 kullanıcı (3 dk)	1.125	1.125 (%100)	0	0	0	1,60 sn	1,69 sn	6,20

Kademe	İstek	Tam sonuç	Kısmi	5xx	Bağlantı hatası	Medyan	p95	İstek/sn
25 kullanıcı (3 dk)	1.125	1.125 (%100)	0	0	0	4,03 sn	4,30 sn	6,12
50 kullanıcı (3 dk)	1.089	1.089 (%100)	0	0	0	8,64 sn	9,03 sn	5,82
100 kullanıcı (3 dk)	1.080	1.080 (%100)	0	0	0	18 sn	19 sn	5,51
100 istek aynı anda	100	100 (%100)	0	0	0	9,46 sn	17 sn	5,58
1.000 istek aynı anda	561	98 (%17)	68	246	149	17 sn	29 sn	17,60
5.000 istek aynı anda	3.223	89 (%3)	0	756	2.378	–	19 sn	88,78

1.000 ve 5.000 isteklik kademeler hata oranı eşiği nedeniyle ~30 saniyede durdurulmuştur; tabloda durdurma anına kadar gönderilen istekler yer almaktadır.

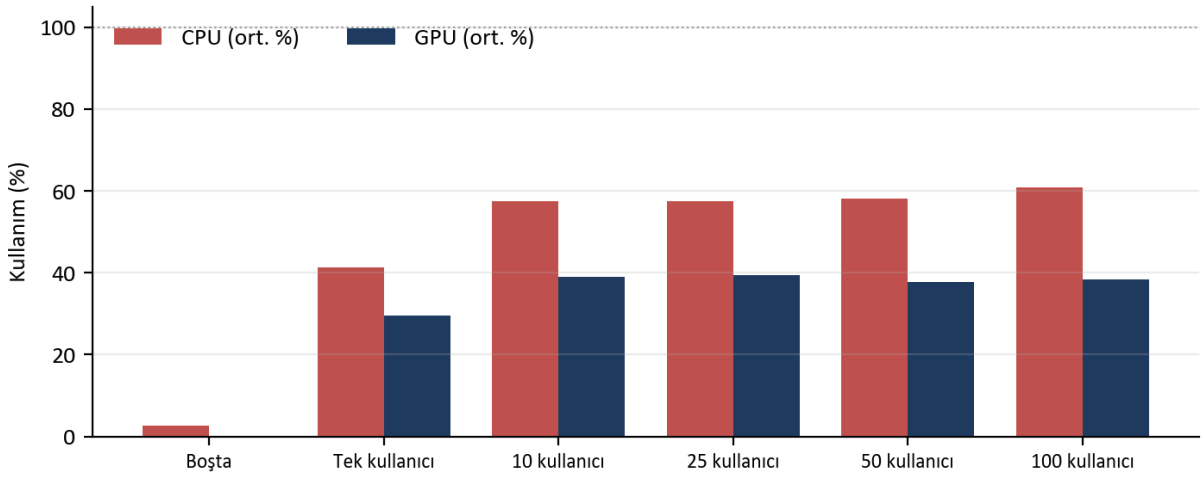


Şekil 2 — Eşzamanlı kullanıcı sayısına göre yanıt süresi ve throughput

Throughput 10 kullanıcıda saniyede 6,2 analize ulaşıp sabit kalmaktadır. Bu noktadan sonra yanıt süresi kullanıcı sayısıyla doğrusal artar (100 kullanıcıda medyan 18 sn). 10 eşzamanlı kullanıcıya kadar yanıt süresi 2 saniyenin altındadır.

3.3 Sunucu kaynak kullanımı

Dönem	CPU ort.	GPU ort.	Load (en yüksek, 4 vCPU)	Boş RAM (en düşük)	VRAM (en yüksek)
Boşta	%3	%0	0,0	3,8 GB	10,0 / 15 GB
Tek kullanıcı	%41	%30	1,9	3,7 GB	10,0 / 15 GB
10 kullanıcı	%58	%39	2,7	3,7 GB	10,0 / 15 GB
25 kullanıcı	%57	%39	2,8	3,6 GB	10,3 / 15 GB
50 kullanıcı	%58	%38	3,2	3,4 GB	10,6 / 15 GB
100 kullanıcı	%61	%38	3,3	3,3 GB	10,6 / 15 GB



Şekil 3 — Yük kademelerine göre ortalama CPU ve GPU kullanımı

Analiz başına donanım maliyeti

Kaynak	Analiz başına	Hesaplama
GPU zamanı (T4)	~0,08 sn	Tek kullanıcıda ort. GPU %30 ÷ 3,9 analiz/sn
CPU zamanı	~0,4 çekirdek-sn	Ort. CPU %41 × 4 vCPU ÷ 3,9 analiz/sn
Model ağırlıkları	~760 MB	İki modelin disk boyutu (FP32)

Bu değerler sunucudaki tüm servislerin toplam kullanımından türetilmiş üst sınır tahminleridir; GPU belleği (VRAM) sunucuda yüklü olan diğer modelleri de içerdiğinden akışa ait bellek ayrıca ölçülmelidir.

4. Gömülü / araç içi kullanım için değerlendirme

4.1 Ölçümlerin desteklediği

- Akış tek kullanıcıda **254 ms** gibi etkileşimli kullanıma uygun bir sürede ve çok düşük sapmayla (p99 280 ms) yanıt vermektedir.
- Modeller base boyutludur (~95 milyon parametre/model) ve toplam ağırlık ~760 MB'tır; bu ölçek, güncel araç ve gömülü yapay zekâ platformlarının bellek bütçesine sığabilecek düzeydedir.
- Analiz başına GPU ve CPU maliyeti düşüktür; sunucu tam yükte dahi doymamıştır.
- Akış kararlıdır: tek kullanıcı ve 100 kullanıcıya kadar olan tüm kademelerde sıfır hata ve sıfır eksik sonuç.

4.2 Henüz ölçülmeyen

- Ölçümler veri merkezi sınıfı bir GPU (NVIDIA T4) üzerinde yapılmıştır. Araç donanımındaki gerçek yanıt süresi, hedef platformda (ör. NVIDIA Jetson Orin veya araç SoC'si) ayrı bir ölçümle doğrulanmalıdır.
- Akışa ait bellek (RAM/VRAM) tek başına ölçülmemiştir; sunucuda diğer modeller de yüklüdür.
- Uzun süreli çalışmada bellek davranışı: sunucunun boş RAM'i gün boyunca azalmış ve yük bittikten sonra geri gelmemiştir. Saatlerce açık kalacak bir araç sistemi için bu davranış servis bazında incelenmelidir.
- Model sıkıştırma (FP16/INT8 nicemleme, ONNX/TensorRT) uygulanmamıştır; bu teknikler gömülü platformda süre ve belleği ayrıca düşürebilir.

5. Sonraki adımlar

No	Adım	Amaç
1	Akışı yalnızca bu iki modelle, kısıtlı kaynaklı bir konteynerde (ör. 4 çekirdek, 8 GB, yalnız CPU) ölçmek	Gömülü donanım öncesi hızlı tahmin
2	Hedef platformda (ör. Jetson Orin) uçtan uca süre, bellek ve güç ölçümü	Sunum için doğrulanmış araç içi sayılar
3	FP16/INT8 nicemleme ve ONNX/TensorRT dönüşümü	Süre ve belleği düşürmek
4	2–3 saatlik tek kullanıcı dayanıklılık testi, servis bazında bellek izleme	Uzun süreli kararlılık
5	Bulut tarafı: servislerde birden fazla worker / istek gruplama; eşzamanlılık sınırı ve rate limit	Kapasite ve aşırı yük koruması
6	Kısmi sonuçta açık hata durumu (200 yerine 503 veya yanıtta "partial" bayrağı)	Eksik sonucun fark edilmesi

6. Kısıtlar

- Yük tek bir istemciden (Windows, ev internet bağlantısı) üretilmiştir; 10.000 ve üzeri eşzamanlı istek kademeleri çalıştırılmamıştır.
- Ani yük kademelerindeki bağlantı hatalarının bir kısmı istemci ağından kaynaklanıyor olabilir.
- Test, canlı sistem üzerinde yapılmıştır. TOGG yanıtlarında kullanılan skor çeşitlendirme (diversify) katmanı açıktır; bu katman süreyi değil, yalnızca skor değerlerini etkiler.
- Tüm isteklerde aynı kısa ses kaydı kullanılmıştır; daha uzun kayıtlarda süreler artacaktır.

Karşılaştırma: aynı gün aynı sunucuda ölçülen genel analiz (/analyze-fused; konuşma tanıma dahil tüm modeller) tek istekte 3,34 sn, en yüksek hızda saniyede 0,57 analiz yapmıştır. Ayrıntılar: DiagVoice API Yük Testi Raporu (10 Kasım 2026).