API Yük Testi Raporu

DiagVoice ses ve metin analizi servisi — mevcut sistem

Test tarihi	10 Kasım 2026, 14:11–15:15 UTC (17:11–18:15 TSİ)
Hedef sistem	aiapi.diagvoice.com (AWS g4dn.xlarge, tek sunucu)
Kod sürümü	feat/prod-hardening, commit ee61b56
Araç	Grafana k6 2.3.0; sunucu tarafında 1 sn aralıklı kaynak izleme
Kapsam	/analyze-fused, /analyze-text-sentiment, GET /
Belge durumu	Sürüm 1.0 — Şirket içi

1. Yönetici özeti

Bu test, DiagVoice API'sinin bugünkü haliyle (rate limit, istek kuyruğu ve yatay ölçekleme olmadan) artan yük altındaki davranışını ölçmek amacıyla yapılmıştır. Sonuçlar, yol haritasındaki kimlik doğrulama/rate limit (F1), model servislerinin ayrıştırılması (F2) ve kuyruk sistemi (F4) çalışmalarına girdi olarak kullanılacaktır.

- **Ses analizi kapasitesi saniyede yaklaşık 0,57 istektir** (saatte ~2.100.0). Bu sınıra 10 eşzamanlı kullanıcıda ulaşılmakta; daha fazla kullanıcı throughput'u artırmamakta, yalnızca bekleme süresini uzatmaktadır.
- **Darboğaz GPU değil, CPU'dur.** Ses analizi yükü altında CPU ortalama %77–92 doluluktayken GPU ortalama %23–34 kullanılmaktadır. 4 vCPU'lu g4dn.xlarge'da ses çözme ve akustik özellik çıkarma işlemleri CPU'yu doyurmaktadır.
- **Cloudflare'in 100 saniyelik zaman aşımı gerçek kullanıcılar için kritik bir risktir.** 100 eşzamanlı kullanıcıda bekleme süresi 100 saniyeyi aşmakta ve istekler sunucu yanıt vermeden 5xx ile sonlanmaktadır. Cloudflare atlandığında aynı yükte isteklerin tamamı başarılı olmuş, ancak bekleme 4–5 dakikaya çıkmıştır.
- **1.000 ani ses analizi isteğinde sistem kuyruklamak yerine hızlı hata vermektedir:** isteklerin bir kısmı ilk saniyede reddedilmiş, bir kısmı 15 saniyede 5xx ile, bir kısmı ise 20 saniye içinde muhtemelen eksik model sonuçlarıyla 200 olarak dönmüştür.
- **Metin analizi rahattır:** saniyede ~90 istek, 100 eşzamanlı kullanıcıda dahi hatasız.
- **Ani 1.000+ bağlantıda bağlantıların %16–21'i ilk saniyede reddedilmektedir**; sunucu CPU'su bu sırada %14'ün altındadır, yani sınır işlem gücünde değil bağlantı kabul katmanındadır.
- **Sunucu hiçbir kademede çökmemiş**, her kademeden sonra en geç 20 saniye içinde sağlıklı yanıt vermeye dönmüştür.
- **İstemci bağlantısı koptuğunda sunucu işi iptal etmemektedir:** 1.000 isteklik kademe durdurulduktan sonra sunucu yaklaşık 7 dakika boyunca sahipsiz istekleri işlemeye devam etmiştir.

2. Kapsam ve yöntem

2.1 Test edilen uç noktalar

Uç nokta	İçerik	Neyi temsil ediyor
POST /analyze-fused	Ses dosyası (m4a, 150 KB): STT + duygu + sağlık modelleri	Gerçek kullanım; en ağır iş
POST /analyze-text-sentiment	Kısa Türkçe metin, tek BERT modeli (GPU)	Hafif model çağrısı
GET /	Servis bilgisi; model çalıştırmaz	Karşılama katmanı: nginx, uvicorn, audit kaydı

2.2 Yük modeli

- **Sürekli yük:** N sanal kullanıcı 3 dakika boyunca, her biri bir önceki yanıtı aldıktan hemen sonra yeni istek gönderir.
- **Ani yük ("aynı anda"):** N istek aynı anda başlatılır, her kullanıcı tek istek gönderir.
- Her kademede hata oranı 30 saniye sonra %50'yi aşarsa kademe otomatik durdurulmuştur. Kademeler arasında 60 saniye beklenmiş ve sunucunun sağlıklı yanıt vermesi şartı aranmıştır.
- Yük, tek bir istemci makineden (Windows, ev internet bağlantısı) üretilmiştir.

2.3 Ağ yolu

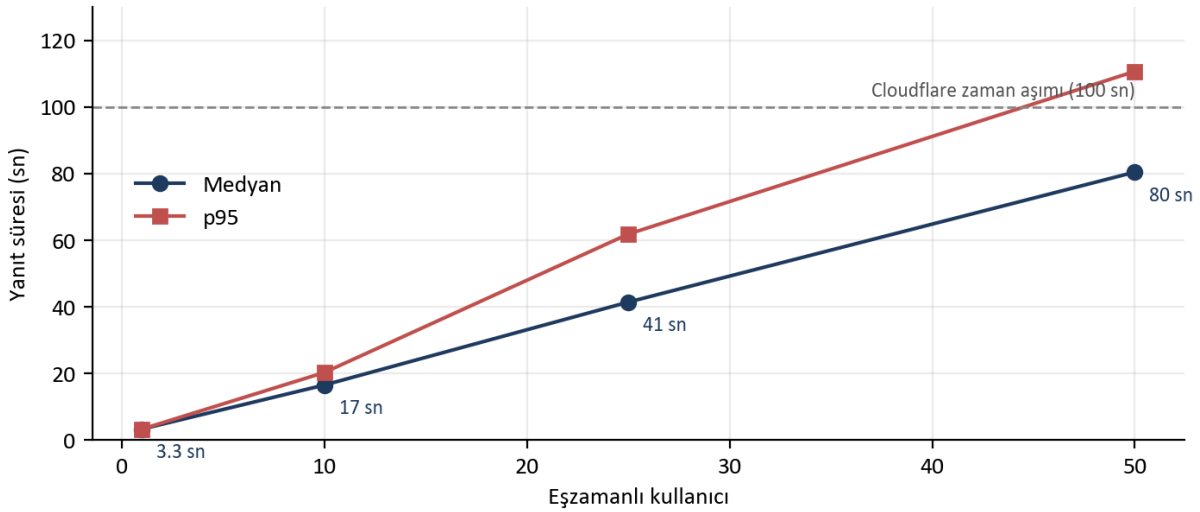
Test sırasında **aiapi.diagvoice.com** alan adının Cloudflare proxy'si arkasında olduğu tespit edilmiştir. Ses analizi kademeleri önce Cloudflare üzerinden çalıştırılmış; Cloudflare'in kendi sınırlarının sonuçları maskelediği görülünce metin ve GET / kademeleri ile ses analizinin yüksek kademeleri **doğrudan sunucuya** (aynı alan adı ve TLS sertifikası, Cloudflare atlanarak) tekrarlanmıştır.

3. Sonuçlar

3.1 Ses analizi — /analyze-fused (Cloudflare üzerinden)

Kademe	İstek	Başarılı (2xx)	5xx	Bağlantı hatası	Medyan	p95	En uzun	İstek/sn
1 istek	1	1 (%100)	0	0	3,34 sn	3,34 sn	3,34 sn	0,27
10 kullanıcı (3 dk)	111	111 (%100)	0	0	17 sn	20 sn	44 sn	0,59
25 kullanıcı (3 dk)	115	114 (%99)	0	1	41 sn	62 sn	77 sn	0,56
50 kullanıcı (3 dk)	134	134 (%100)	0	0	80 sn	111 sn	124 sn	0,56
100 kullanıcı (3 dk)	62	24 (%39)	38	0	127 sn	127 sn	127 sn	0,48
100 istek aynı anda	69	0 (%0)	69	0	127 sn	127 sn	127 sn	0,54
1.000 istek aynı anda	70	1 (%1)	63	6	22 sn	25 sn	30 sn	2,20

100 kullanıcı ve üzeri kademeler hata oranı eşiği nedeniyle erken durdurulmuştur. 1.000 isteklik kademede tabloda yalnızca durdurma anına kadar tamamlanan istekler yer almaktadır. ~127 saniyede kesilen 5xx yanıtlar Cloudflare zaman aşımına (HTTP 524) karşılık gelmektedir.



Şekil 1 — Eşzamanlı kullanıcı sayısına göre ses analizi yanıt süresi (başarılı istekler)

Throughput 10, 25 ve 50 kullanıcıda sırasıyla 0,59, 0,56 ve 0,56 istek/sn ile sabit kalmıştır. Yanıt süresi eşzamanlılıkla doğrusal artmaktadır (Little yasası: 50 kullanıcı / 0,56 istek/sn ≈ 89 sn; ölçülen medyan 80 sn). Bu, isteklerin sunucuda sıra beklediğini ve ek kullanıcıların kapasiteyi artırmadığını göstermektedir.

3.2 Ses analizi — /analyze-fused (doğrudan sunucu)

Kademe	İstek	Başarılı (2xx)	5xx	Bağlantı hatası	Medyan	p95	En uzun	İstek/sn
100 kullanıcı (3 dk)	102	102 (%100)	0	0	267 sn	317 sn	317 sn	0,32
1.000 istek aynı anda	376	102 (%27)	86	188	15 sn	27 sn	29 sn	11,79

Cloudflare atlandığında 100 kullanıcılı kademede isteklerin tamamı başarıyla tamamlanmış, ancak medyan bekleme 4,5 dakikaya çıkmıştır. Kademe başladığında sunucu önceki koşudan kalan istekleri hâlâ işlediği için throughput (0,32 istek/sn) ilk ölçümün altında kalmıştır. 1.000 isteklik kademede ilk saniyede 175 bağlantı reddedilmiş; ardından 86 istek ortalama 15 saniyede 5xx ile, 102 istek ise 20 saniye içinde 200 ile dönmüştür. Sunucunun kapasitesi düşünüldüğünde bu hızlı 200 yanıtlarının bazı modellerin hata alanıyla döndüğü kısmi sonuçlar olması kuvvetle muhtemeldir (yanıt gövdeleri bu testte kaydedilmemiştir). Kademe, hata oranı eşiği nedeniyle 32. saniyede durdurulmuştur.

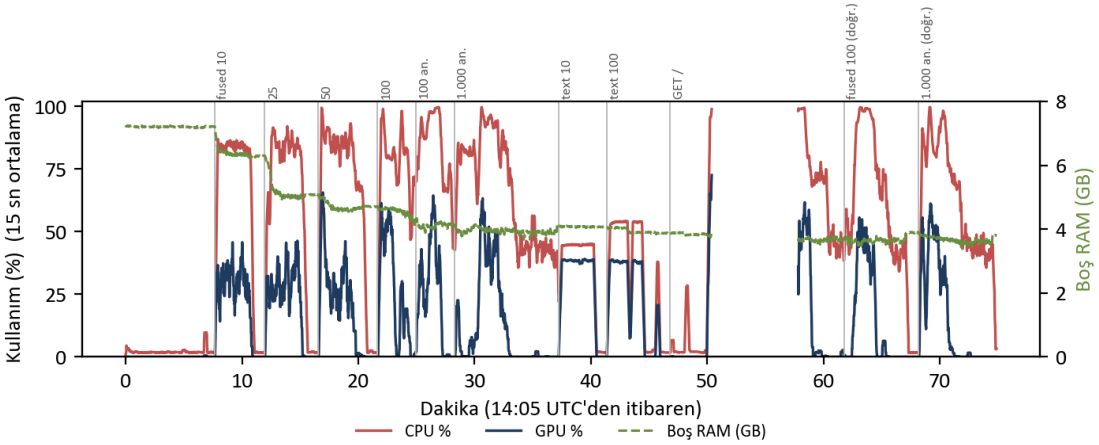
3.3 Metin analizi ve karşılama katmanı (doğrudan sunucu)

Kademe	İstek	Başarılı (2xx)	5xx	Bağlantı hatası	Medyan	p95	En uzun	İstek/sn
/analyze-text-sentiment								
1 istek	1	1 (%100)	0	0	0,28 sn	0,28 sn	0,28 sn	2,00
10 kullanıcı (3 dk)	16.988	16.988 (%100)	0	0	0,10 sn	0,12 sn	0,20 sn	94,34
100 kullanıcı (3 dk)	14.133	14.133 (%100)	0	0	1,19 sn	1,22 sn	13 sn	78,08
1.000 istek aynı anda	1.000	789 (%79)	0	211	3,20 sn	8,55 sn	9,90 sn	93,34
GET /								
1.000 istek aynı anda	1.000	835 (%84)	0	165	0,11 sn	0,16 sn	0,23 sn	338,02
5.000 istek aynı anda	5.000	4.190 (%84)	0	810	0,22 sn	2,08 sn	12 sn	301,27

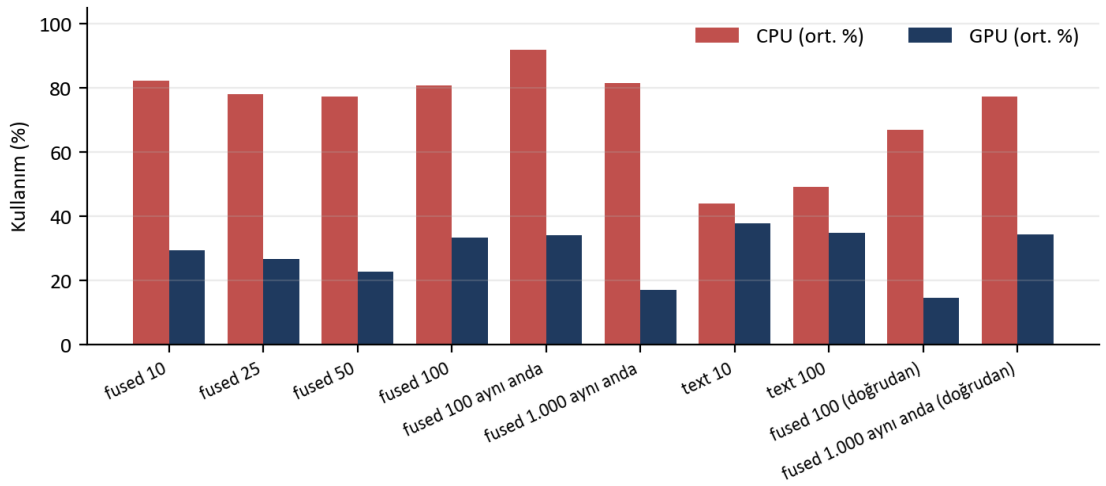
Bağlantı hataları istemci tarafında "bağlantı uzak sunucu tarafından kapatıldı" ve "EOF" olarak görülmüş, tamamı kademenin ilk 1–2 saniyesinde oluşmuştur. Sunucuya ulaşan isteklerin hiçbiri 5xx ile sonuçlanmamıştır.

3.4 Sunucu kaynak kullanımı

Dönem	CPU ort.	GPU ort.	Load (en yüksek, 4 vCPU)	Boş RAM (en düşük)	VRAM (en yüksek)
Boşta	%2	%0	0,3	7,2 GB	9,1 / 15 GB
fused 10	%82	%29	6,2	6,2 GB	9,5 / 15 GB
fused 25	%78	%27	8,2	4,9 GB	9,7 / 15 GB
fused 50	%77	%23	8,6	4,5 GB	9,7 / 15 GB
fused 100	%81	%33	7,0	4,4 GB	9,7 / 15 GB
fused 100 aynı anda	%92	%34	11,1	3,9 GB	9,8 / 15 GB
fused 1.000 aynı anda	%81	%17	10,1	3,7 GB	9,8 / 15 GB
İptal sonrası (7 dk)	%69	%14	10,6	3,7 GB	9,8 / 15 GB
text 10	%44	%38	6,4	4,0 GB	9,8 / 15 GB
text 100	%49	%35	2,4	3,9 GB	10,0 / 15 GB
GET / 1.000	%6	%0	0,3	3,9 GB	10,0 / 15 GB
GET / 5.000	%14	%0	0,3	3,8 GB	10,0 / 15 GB
fused 100 (doğrudan)	%67	%15	11,4	3,4 GB	10,0 / 15 GB
fused 1.000 aynı anda (doğrudan)	%77	%34	3,1	3,8 GB	10,0 / 15 GB
İptal sonrası (doğrudan, 6 dk)	%63	%13	11,7	3,4 GB	10,0 / 15 GB



Şekil 2 — Test boyunca sunucu CPU, GPU ve boş RAM değişimi (dikey çizgiler kademe başlangıçlarıdır)



Şekil 3 — Kademelere göre ortalama CPU ve GPU kullanımı

4. Bulgular ve değerlendirme

No	Önem	Bulgu
B1	Yüksek	**Ses analizinin darboğazı CPU** Ses analizi yükünde CPU %77–92, sistem yükü (load) 4 çekirdek için 6–11 seviyesindeyken GPU ortalama %23–34 kullanılmıştır. Ses çözme (ffmpeg), librosa/openSMILE/Praat ile akustik özellik çıkarma ve benchmark modeli CPU'da çalışmaktadır. GPU'yu büyütmek kapasiteyi artırmaz; 8 vCPU'lu g4dn.2xlarge (aynı T4 GPU) kapasiteyi kabaca iki katına çıkarabilir.
B2	Yüksek	**Cloudflare zaman aşımı (100 sn)** Sıradaki bekleme 100 saniyeyi aştığında Cloudflare isteği sonlandırmaktadır. Mevcut kapasiteyle bu durum ~55 eşzamanlı ses analizi isteğinde başlar. Aynı yük Cloudflare atlanarak uygulandığında isteklerin tamamı başarılı olmuştur; yani bu hatalar sunucudan değil, Cloudflare sınırından kaynaklanmaktadır. nginx'te tanımlı 900 saniyelik zaman aşımı Cloudflare arkasında geçerli değildir.
B3	Yüksek	**Aşırı yükte koruma yok** Rate limit veya kabul kontrolü olmadığından fazla istek reddedilmek yerine sıraya girmekte ve tüm kullanıcıların bekleme süresini uzatmaktadır. Tek bir istemcinin yoğun trafiği diğer müşterileri (ör. TOGG) doğrudan etkilemektedir.
B4	Yüksek	**Ani yükte hızlı hata ve olası kısmi yanıtlar** 1.000 ani ses analizi isteğinde (doğrudan sunucu) istekler kuyrukta beklemek yerine 15–20 saniye içinde 5xx ya da 200 ile dönmüştür. fusion servisinin iç servislere açtığı bağlantı havuzu 64 ile sınırlıdır; aşımda iç çağrıların hata verip ana yanıtın eksik model sonuçlarıyla 200 dönmesi beklenen davranıştır. İstemci 200 aldığı halde eksik sonuç alıyor olabilir; yanıt gövdeleriyle doğrulanmalıdır.
B5	Orta	**Kopan istekler iptal edilmiyor** 1.000 isteklik kademe 14:33:52'de durdurulduktan sonra sunucu 14:41'e kadar %60–100 CPU ile çalışmaya devam etmiştir. Aynı durum doğrudan sunucu koşusunda da tekrarlanmıştır (15:13:48'de durdurma, 15:19:38'e kadar yük). Yanıtı bekleyen kimse olmayan işler kapasite tüketmekte ve sonraki kullanıcıları bekletmektedir.
B6	Orta	**Ani bağlantılarda kabul katmanı sınırı** 1.000 ve 5.000 ani bağlantıda bağlantıların %16–21'i ilk saniyede reddedilmiştir; sunucu CPU'su %14'ün altındadır. Olası nedenler nginx listen backlog (varsayılan 511) ve worker_connections sınırıdır. Tek istemci makinenin ağ sınırları da katkıda bulunmuş olabilir; nginx hata günlüğü ile doğrulanmalıdır.
B7	Orta	**Bellek geri dönmüyor** Boş RAM test başında 7,3 GB iken 3,5 GB'a düşmüş ve yük bittikten sonra toparlanmamıştır. Sızıntı ya da model/önbellek büyümesi olabilir; uzun süreli yükte bellek yetersizliği riski vardır. Servis bazında bellek ölçümü yapılmalıdır.

No	Önem	Bulgu
B8	Bilgi	**GPU belleği yeterli** VRAM en fazla 10,3 / 15 GB kullanılmış, hiçbir kademede GPU bellek hatası oluşmamıştır.
B9	Bilgi	**Kararlılık** Hiçbir kademede servis çökmesi yaşanmamış; sunucu her kademeden sonra en geç 20 saniye içinde sağlıklı yanıt vermiştir.

5. Öneriler

Öncelik	Öneri	İlgili bulgu	Yol haritası
1	API anahtarı bazlı rate limit ve eşzamanlı ses analizi sınırı; sınır aşımında hemen 429 yanıtı	B2, B3, B4	F1
2	Ses analizi için asenkron iş API'si (iş gönder → sonucu sorgula); Cloudflare zaman aşımını ortadan kaldırır	B2, B5	F4
3	Kopan/zaman aşımına uğrayan istekleri iptal eden kuyruk (Redis + worker)	B5	F4
4	CPU yoğun özellik çıkarmayı ayrı CPU worker'a taşımak; kısa vadede g4dn.2xlarge değerlendirmesi	B1	F2 / F3
5	nginx: listen backlog, worker_connections ve somaxconn ayarlarının artırılması	B6	F3
6	Kısmi sonuçlarda 200 yerine açık hata durumu (ör. 503 + eksik modeller listesi) ya da yanıtta "partial" bayrağı	B4	F1
7	Servis bazında bellek izleme ve sızıntı analizi	B7	—

6. Kısıtlar

- Yük tek bir istemciden (16 GB RAM'li Windows makine, ev internet bağlantısı) üretilmiştir. Bu nedenle 10.000, 25.000 ve 50.000 eşzamanlı bağlantı kademeleri çalıştırılmamıştır; bu kademeler için ayrı bir Linux yük makinesi gerekmektedir.
- Ani bağlantı kademelerindeki reddedilmelerin ne kadarının sunucudan, ne kadarının istemci ağından kaynaklandığı sunucu günlükleriyle henüz doğrulanmamıştır.
- Test, canlı sistem üzerinde yapılmıştır; aynı saatlerde gelen gerçek trafik sonuçlara az miktarda karışmış olabilir.
- Tüm ses isteklerinde aynı 150 KB'lık örnek kayıt kullanılmıştır; daha uzun kayıtlar süreleri orantılı olarak artıracaktır.
- Sunucu kaynak verileri iki ayrı kayıttan birleştirilmiştir; 14:55–15:03 UTC aralığında kayıt yoktur (Şekil 2'deki boşluk).